admissao_universidade

October 27, 2025

1 Previsão para admissão na faculdade

1.1 Introdução

Baseado no dataset do Kaggle, vou criar um modelo utilizando regressão linear que prevê a chance de admissão de novos alunos em universidades mediante seu histórico escolar e notas.

1.2 Modelo

1.2.1 Carregando o DataFrame

Vamos começar importando as bibliotecas necessárias e carregar o dataset para começarmos.

[1]:
```
# Importando bibliotecas
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Carregando o dataframe
admission_df = pd.read_csv('graduate_admission.csv')

# Mostrando as 5 primeiras linhas
admission_df.head()
```

[1]:

	GRE Score	TOEFL Score	University Rating	SOP	LOR	GPA	Research	Chance of Admit
0	295	96	2	4.9	1.7	2.93	0	0.612
1	340	119	3	4.1	1.7	3.76	0	0.708
2	336	96	1	3.2	1.8	3.12	1	0.728
3	337	108	4	3.4	1.3	2.11	0	0.643
4	323	98	1	1.1	1.3	3.40	0	0.524

[2]:
```
# Informações do dataframe
print(f'Há {admission_df.shape[0]} linhas e {admission_df.shape[1]} colunas.')
print('\n')
print('INFORMAÇÕES TÉCNICAS')
print(admission_df.info())
print('\n')
print('INFORMAÇÕES ESTATÍSTICAS')
print(admission_df.describe())
```

```
Há 1000 linhas e 8 colunas.


INFORMAÇÕES TÉCNICAS
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 8 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   GRE Score          1000 non-null   int64
 1   TOEFL Score        1000 non-null   int64
 2   University Rating  1000 non-null   int64
 3   SOP                1000 non-null   float64
 4   LOR                1000 non-null   float64
 5   GPA                1000 non-null   float64
 6   Research           1000 non-null   int64
 7   Chance of Admit    1000 non-null   float64
dtypes: float64(4), int64(4)
memory usage: 62.6 KB
None


INFORMAÇÕES ESTATÍSTICAS
         GRE Score  TOEFL Score  University Rating          SOP          LOR   \
count  1000.000000  1000.000000        1000.000000  1000.000000  1000.000000
mean    315.840000   106.459000           3.053000     2.997000     3.014400
std      15.083432     8.449954           1.421341     1.163239     1.163136
min     290.000000    92.000000           1.000000     1.000000     1.000000
25%     303.000000    99.000000           2.000000     2.000000     2.000000
50%     316.000000   107.000000           3.000000     3.000000     3.000000
75%     329.000000   114.000000           4.000000     4.000000     4.000000
max     340.000000   120.000000           5.000000     5.000000     5.000000

               GPA     Research  Chance of Admit
count  1000.000000  1000.000000      1000.000000
mean      3.027160     0.517000         0.729223
std       0.582774     0.499961         0.095161
min       2.000000     0.000000         0.491000
```

```
25%       2.530000      0.000000          0.655000
50%       3.025000      1.000000          0.728500
75%       3.550000      1.000000          0.801000
max       4.000000      1.000000          0.970000
```

1.2.2 Análise exploratória dos dados (EDA)

Podemos observar que a maioria das universidades são nota 3 com uma variância de aproximadamente 1.4, logo os alunos admitidos estarão entrando em faculdades com boa reputação. Para isso, a maioria dos alunos conta com notas no TOEFL e GRE (Graduate Record Examination) de 315.8 e 106.4, respectivamente. Para ser aprovado nestes exames é necessário uma nota igual ou superior a 320 no GRE (nesta prova não há um número certo, sendo essa pontuação considerada boa para o exame) e 90 no TOEFL (também não é preciso, apenas uma média considerada aceitável).

1.2.3 Modelo de regressão

[13]:
```
# Importando função para separar treino e teste
from sklearn.model_selection import train_test_split

# Separando as features do target
X = admission_df.drop(columns='Chance of Admit') # features
y = admission_df['Chance of Admit'] # target

# Separando em treino e test
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,␣
 ↪random_state=42)

# Conferindo o shape(quantidade) de cada
print(f'Há {X_train.shape[0]} dados de features para treino.')
print(f'Há {X_test.shape[0]} dados de features para teste.')
print(f'Há {y_train.shape[0]} dados de target para treino.')
print(f'Há {y_test.shape[0]} dados de target para teste.')
```

```
Há 800 dados de features para treino.
Há 200 dados de features para teste.
Há 800 dados de target para treino.
Há 200 dados de target para teste.
```

Como pode-se perceber nas colunas, há dados que não estão normalizados entre si, com valores discrepantes. Para isso iremos normalizá-los com a função *StandardScaler* da ScikitLearn.

[4]:
```
# Importando alforitmo e função importantes para performance do modelo
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler

# Padronizando as colunas
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
```

```
X_test_scaled = scaler.transform(X_test)

# Instanciando uma variável para a função da regressão linear
model = LinearRegression()

# Modelando a variável com nossos dados de treino
model.fit(X_train_scaled, y_train)
```

[4]:
```
LinearRegression()
```

[5]:
```
# Criando nossas predições
y_pred = model.predict(X_test_scaled)
```

Agora que treinamos e testamos nosso modelo, vamos avaliá-lo!

1.2.4 Avaliando o modelo

Vamos começar plotando um gráfico de dispersão, mostrando o valor real X valor predito, e uma linha que representa quando o modelo acerta.

[14]:
```
# Plotando o gráfico de dispersão
plt.scatter(y_test, y_pred)
# Criando a linha para melhor análise
plt.plot([y_test.min(), y_test.max()],
                [y_test.min(), y_test.max()],
                'r--', lw=3)
# Mostrando o gráfico no nosso output
plt.show()
```

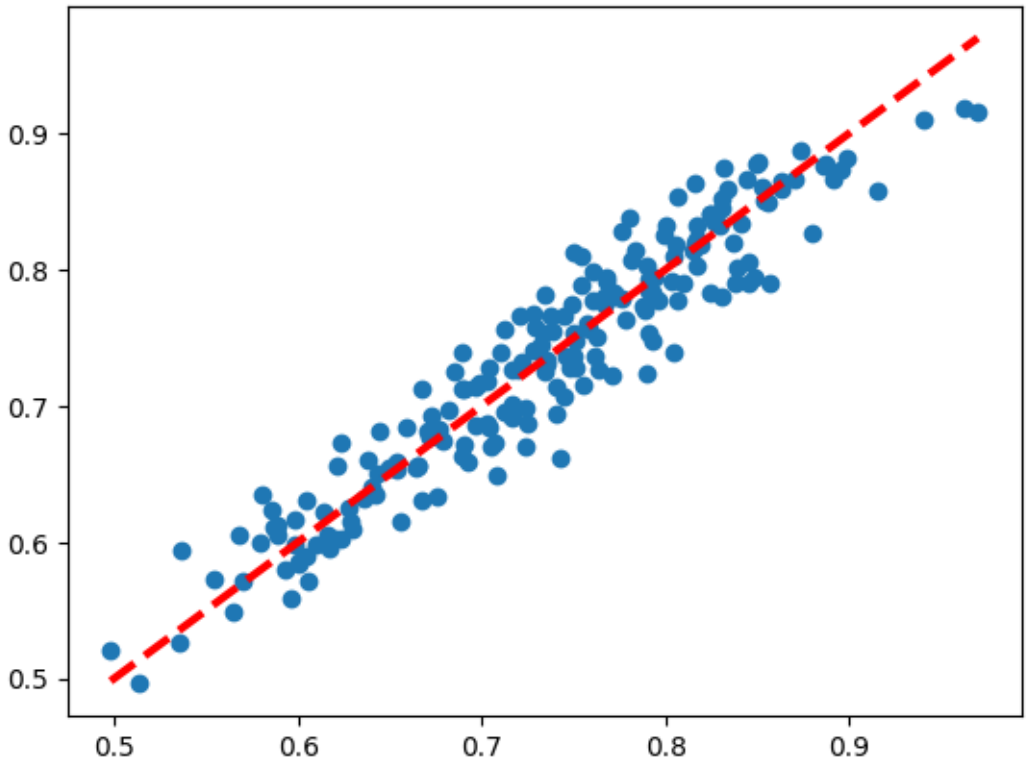

Visualmente, podemos ver que o modelo parece ter performado bem. Para sabermos melhor, vamosm utilizar de ferramentas estatísticas para avaliar!

Usando medidas estatísticas Vamos utilizar a validação cruzada para avaliar o modelo e depois mostrar as correlações das colunas com o target selecionado.

[27]:
```
# Validação cruzada
from sklearn.model_selection import cross_val_score

# Invocando a função
cross_val = cross_val_score(model, X_train_scaled, y_train, cv=5, scoring='r2')
# Printando os resultados no output
print(f'R2 ajustado: {cross_val.mean():.3f} (+/- {cross_val.std():.3f})')
```

```
R2 ajustado: 0.897 (+/- 0.009)
```

[28]:
```
# Correlações com a coluna 'Chance of Admit' (target)
correlation = admission_df.corr()['Chance of Admit']
print(correlation)
```

```
GRE Score            0.103643
TOEFL Score          0.095582
University Rating    0.295981
```

```
SOP                0.206102
LOR                0.246334
GPA                0.256385
Research           0.760349
Chance of Admit    1.000000
Name: Chance of Admit, dtype: float64
```

1.3 Conclusão

Pode-se concluir que o nosso modelo, dentro dos dados treinados, performou muito bem. Estou satisfeito com o resultado mas mesmo assim precisamos de dados externos para validar o modelo, ver se realmente ele está treinado.

[ ]: